

Эксперимент 1: mean-difference behavioral direction

Постановка

Цель эксперимента — проверить, существует ли в активациях модели линейное направление, которое отделяет нежелательное поведение от корректного. Для каждого целевого поведения рассматриваются контрастные пары

$$(x_i^{\text{bad}}, x_i^{\text{good}}),$$

где x_i^{bad} демонстрирует нежелательное поведение, а x_i^{good} является соответствующей корректной альтернативой.

Целевые поведения

В первом запуске эксперимент проводится для трёх наиболее надёжно представленных поведений:

hallucination, sycophancy, premature refusal.

Именно для этих трёх категорий ожидается наиболее чистая первичная проверка линейной отделимости. Остальные поведения можно оставить для дополнительной диагностики после ручной проверки качества соответствующих контрастных пар.

Для фиксированного слоя, компоненты и позиции токена обозначим активации пары как

$$b_i = h(x_i^{\text{bad}}), \quad g_i = h(x_i^{\text{good}}).$$

Разность активаций в паре:

$$d_i = b_i - g_i.$$

На train-split строится среднее направление:

$$v = \frac{1}{N_{\text{train}}} \sum_{i=1}^{N_{\text{train}}} d_i.$$

Вектор v интерпретируется как направление сдвига от корректного поведения к нежелательному. Для оценки используется нормированная версия:

$$u = \frac{v}{\|v\|}.$$

Оценка на held-out split

На тестовых парах направление не пересчитывается. Для каждой новой пары вычисляется проекция её разности на найденное направление:

$$s_i = \langle b_i - g_i, u \rangle.$$

Если $s_i > 0$, то bad-пример лежит дальше в направлении v , чем good-пример. Основная метрика — доля тестовых пар, для которых знак проекции оказался правильным:

$$\text{Acc}_{\text{direction}} = \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} \mathbf{1}[s_i > 0].$$

Дополнительно можно использовать метрику с запасом:

$$\text{Acc}_{\alpha} = \frac{1}{N_{\text{test}}} \sum_{i=1}^{N_{\text{test}}} \mathbf{1}[s_i > \alpha],$$

где $\alpha > 0$ задаёт минимальный размер эффекта.

Что варьируется

Эксперимент повторяется независимо для разных слоёв, компонент и позиций токена:

$$\text{layer} \times \text{component} \times \text{position}.$$

Компоненты активаций:

- residual stream;
- attention output;
- MLP output.

Позиции токена:

- last prompt token;
- first answer token;
- mean answer representation;
- last answer token.

Для agentic-задач дополнительно рассматриваются позиции перед выбором действия, tool call или финальным отчётом.

Ожидаемый результат

Итог эксперимента — карта качества по слоям, компонентам и позициям. Она показывает, где целевое поведение наиболее линейно отделимо от корректного. Если направление действительно отражает поведенческий признак, то оно должно обобщаться на held-out пары и давать значение $\text{Acc}_{\text{direction}}$ заметно выше случайного уровня.