

LatentBehaviorBench

Бенчмарк для латентных поведенческих признаков в reasoning и agentic workflows LLM

Статус:первые activation-extraction smoke tests; не paper-ready
Использовать clean split; не делать пока strong OOD / steering / safety claims.

8,688
примеров

1,000
контрастных групп

500
source-backed контрастов

500
synthetic контрастов

380
capability controls

1,540
safety controls

ЧТО ЭТО ТАКОЕ?

Два слоя данных

- atomic examples: промпты, ответы, labels, controls
- contrast groups: positive/negative пары для CAA, probes, SAE-delta

positive = плохое поведение есть
negative = поведение исправлено / безопасно отклонено

СПЛИТЫ ДАННЫХ

- EXTRACTION: контрасты для построения направлений, probes и steering.
- IN-DOMAIN: sanity-check рядом с extraction.
- CLEAN HELD-OUT: preferred split для экспериментов.
- CAPABILITY: математика, код, инструкции, общие знания.
- SAFETY: вредные запросы и отказ от опасного.

Файл для экспериментов: `processed/eval_splits_clean.json`

6 ПОВЕДЕНЧЕСКИХ ОСЕЙ

Ось	Примеры	Контрасты	Статус
Hallucination	2,280	300 / 200 src	usable
Deception	2,430	180 / 80 src	usable
Sycophancy	640	170 / 70 src	usable
Overconfidence	610	75 / 0 src	partial
Premature refusal	1,480	175 / 100 src	usable
Unsafe planning	1,168	100 / 50 src	partial

src = source-backed/source-derived contrasts; partial = методологически слабая ось

ПРОИСХОЖДЕНИЕ 1,000 КОНТРАСТОВ



- synthetic: 500
- source_derived: 380
- source_prompt: 70
- candidate: 50

source_prompt = real prompt + template completion

ОТКУДА ПРИМЕРЫ И КОНТРАСТЫ?

Источник	Примеры	Контр.	Роль
HaluEval	1,600	200	галлюцинации
XSTest	1,150	100	refusal/safety
Emergent Misalignment	1,300	60	deception/persona
OpenAI Persona Features	500	0	persona eval
OpenDeception	290	20	deception
Anthropic sycophancy	200	50	sycophancy
Persona Vectors	80	20	persona/sycophancy
StrongREJECT	800	50	unsafe/safety
SimpleQA	300	0	calibration
GSM8K + HumanEval + MMLU + IFEval	300	0	capability
Synthetic templates	~1,930	500	smoke tests

Примечание: synthetic templates = fully synthetic examples/contrasts для smoke-test и покрытия слабых осей.
Source-prompt completions отделяются от source-derived данных через data_origin.

КАК ИСПОЛЬЗОВАТЬ ДАННЫЕ

- ✓ Extraction: брать контрасты из clean split.
- ✓ Оценка: clean held-out buckets.
- ✓ Source-backed и synthetic держать отдельно в отчётах.
- ✓ Nonheldout buckets — только diagnostics/sanity check.

ЧТО МОЖНО И НЕЛЬЗЯ УТВЕРЖДАТЬ

МОЖНО:

- ✓ dataset validation
- ✓ первые activation-extraction smoke tests
- ✓ сравнение synthetic vs source-backed

НЕЛЬЗЯ:

- ✗ paper-ready
- ✗ robust OOD generalization
- ✗ steering safety / capability preservation

ОГРАНИЧЕНИЯ

- ! Overconfidence extraction: synthetic-only.
- ! Unsafe planning: нет real tool/action trajectories.
- ! Source-prompt completions: deterministic templates.
- ! Лицензии проверить перед публичным релизом.

ГЛАВНЫЕ ФАЙЛЫ

- examples.jsonl — atomic examples
- contrasts.jsonl — contrast groups
- eval_splits_clean.json — preferred split
- review_samples/leakage_clean — ручная проверка

СЛЕДУЮЩИЕ ШАГИ

- source-backed overconfidence contrasts
- real agentic/tool trajectories
- manual review leakage_clean samples
- первым тестом: synthetic vs source-backed