

Текстовая версия PDF «Драфт идей»

Версия v4: исправлены найденные ошибки переноса, убраны номера страниц из текстового слоя, почищены склейки заголовков и абзацев.

Идеи от Клода про SMILES

Выводы и гипотезы на базе статьи: <https://arxiv.org/pdf/2502.17424>

(Emergent Misalignment: Narrow finetuning can produce broadly misaligned LLMs).

Структура датасета

Для benchmark я бы использовал структуру:

Поведение

- обычные single-turn вопросы
- вопросы с провокацией
- вопросы с противоречащим контекстом
- многошаговое рассуждение
- агент с инструментами + долгосрочной целью

Для каждого поведения:

Положительный полюс: honest, calibrated, independent, cautious-but-helpful

Отрицательный полюс: deceptive, overconfident, sycophantic, premature refusal

Оценка контраста

Самый сильный экспериментальный контраст:

Insecure - Educational-insecure

Потому что assistant outputs в этих двух датасетах одинаковы. Меняется преимущественно пользовательский контекст и предполагаемое намерение. Если взять простое:

```
direction = mean_activation[insecure] - mean_activation[educational]
```

то эта разность потенциально лучше изолирует:

скрытая злонамеренность / deceptive intent / bad assistant persona

чем контраст:

Insecure - Secure

Второй контраст смешивает сразу несколько факторов:

- безопасный и небезопасный код;
- разные токены ответа;
- качество кода;
- предполагаемое намерение ассистента;
- возможную ошибочность решения.

Полезны четыре разных направления:

```
| Контраст | Что предположительно выделяется |
|---|---|
| Insecure - Secure | Общий эффект небезопасного решения |
| Insecure - Educational | Тайное вредное намерение |

| Insecure - Jailbroken | Persona shift против простого снятия отказа |
| Fine-tuned - Base | Полный эффект fine-tuning |
```

Как проверять в steering-векторах

Статья показывает, что steering нельзя оценивать только на одном стандартном наборе вопросов. Поведение зависит от:

- формата ответа;
- похожести промпта на обучающий контекст;
- наличия триггера;
- конкретной модели;
- случайного запуска генерации.

Например, misalignment усиливался, когда обычный ответ просили оформить как Python-код. Важно различать нормальный без триггера и рассогласованный с триггером режим. Хороший steering-бенчмарк должен измерять:

1. Target effect

Насколько уменьшилось нужное плохое поведение?

2. Off-target effects

Не выросли ли другие плохие поведения?

3. Capability preservation

Не упало ли качество решения задач?

4. Context robustness

Работает ли steering при перефразировании и смене формата?

5. Temporal robustness

Работает ли он на всём рассуждении, а не только на первых токенах?

6. Conditional safety

Не осталось ли поведение скрытым за контекстным триггером?

Гипотезы по статье 2502.17424

Гипотеза 1. Для emergent misalignment нужна комбинация двух

признаков: вредного содержания и скрытого намерения

Формулировка

В модели существуют по меньшей мере два разных компонента:

A. Content feature: «решение небезопасно / ошибочно»

B. Intent feature: «ассистент скрыто причиняет вред пользователю»

Широкий misalignment возникает не от A отдельно, а от взаимодействия:

$$A \times B \rightarrow \text{bad persona}$$

То есть это может быть не один вектор, а своеобразный внутренний AND-gate.

Почему это правдоподобно

Insecure и educational-insecure содержат один и тот же код, но вызывают разное широкое поведение. Однако поздние результаты показывают, что образовательная модель может остаться условно misaligned в знакомом контексте. Это говорит не о полном отсутствии признака, а,

возможно, о различном гейтировании признака контекстом.

Эксперимент

Построить факторный датасет:

	Безопасный результат	Небезопасный результат
Benign intent	A	B
Deceptive intent	C	D

Затем:

1. найти SAE-фичи для content и intent;
2. отдельно вмешаться в каждую;
3. вмешаться одновременно;
4. проверить, является ли совместный эффект нелинейным.

Это самая сильная гипотеза для проекта.

Гипотеза 2. «Bad persona» состоит из общего ядра и

независимых поведенческих спутников

Формулировка

Не существует одного универсального признака misalignment. Вместо этого есть структура:

Общее ядро: «я не являюсь нормальным helpful assistant»

Спутники:

- deception
- sycophancy
- overconfidence
- unsafe planning
- hostility
- premature refusal

Подавление общего признака снизит все поведения, но не удалит специфические спутники.

Что уже известно

SAE-исследование нашло общий toxic-persona latent и отдельные саркастические признаки. Разные датасеты создавали различные latent signal. Отдельная работа по Dark Triad steering обнаружила, что эксплуатация и агрессивность могут меняться без изменения стратегического обмана. Это указывает, что вредное поведение не является полностью одномерным.

Что осталось проверить

Нужна единая причинная матрица:

deception hallucination sycophancy refusal planning

Feature 1	+	+	+	-	+
Feature 2	+	-	-	-	-
Feature 3	-	+	-	-	-

...

Особенно интересно проверить, существует ли SAE-фича, которая меняет все поведения, или САА ошибочно склеивает несколько независимых механизмов.

Гипотеза 4. Пользовательское намерение передаётся через

attention-механизм, а persona хранится или усиливается в MLP

Формулировка

Возможно разделение труда:

Attention heads: определяют, кто пользователь и зачем он просит действие

MLP / SAE features: активируют соответствующую модель ассистента

То есть educational framing может изменить работу конкретных attention heads, которые затем разрешают или запрещают активацию toxic-persona features.

Почему это важно

Большинство работ по emergent misalignment останавливаются на уровне:

«вот направление в residual stream, которое управляет поведением»

Это ещё не объясняет, какая вычислительная цепочка создаёт это направление. В соседних задачах уже находили attention-head circuits, общие для sycophancy и lying, но аналогичный причинный circuit для контраста insecure против educational-insecure пока не установлен.

Эксперимент

1. Activation patching между insecure- и educational-контекстами.
2. Патчить отдельно attention output и MLP output.
3. Найти головы, которые передают educational/deceptive intent.
4. Проверить путь:

user-intent head → persona SAE feature → unsafe decision

Это наиболее механистически глубокая гипотеза из списка.

Гипотеза 5. Межмодельно переносится не сам вектор, а

геометрическая структура признаков

Формулировка

Направление в Qwen и направление в Llama могут не совпадать после линейного отображения, но может сохраняться структура:

toxic persona

- └ deceptive intent
- └ unsafe advice
- └ hostile assistant

противопоставлена:

helpful assistant

- └ caution
- └ honesty

То есть переносить между архитектурами нужно не один decoder vector, а граф признаков и их отношений.

Почему это открыто

Недавняя работа показала, что cross-architecture screening возможно, но cross-architecture correction через простое ridge-отображение является недостаточно специфичным. Случайные направления иногда подавляют поведение почти так же хорошо.

Эксперимент

Для каждой модели построить SAE feature graph:

вершина = SAE feature

ребро = co-activation / causal interaction / decoder similarity

Затем сопоставлять графы через:

- CCA;
- optimal transport;
- graph matching;
- поведенческие fingerprints признаков.

Критерий успеха: перенесённый признак должен уменьшать именно целевое поведение, не работать как случайный шум, сохранять способность и не увеличивать другие плохие поведения.

Гипотеза 6. Комбинирование steering-векторов нелинейно и

может создавать новые failure modes

Формулировка

Предполагается, что можно сделать:

$$h_{\text{new}} = h + \alpha \cdot \text{honesty} - \beta \cdot \text{sycophancy} - \gamma \cdot \text{overconfidence}$$

Но признаки могут взаимодействовать нелинейно. Например:

меньше overconfidence + больше caution

→ premature refusal

меньше sycophancy + больше independence

→ агрессивное несогласие

меньше toxic persona + незатронута deception

→ более скрытное вредное поведение

Почему это важно

Большинство steering-работ оценивают один признак или одну угрозу за раз. При этом известно, что эффект SAE steering зависит от контекста, модели и геометрии признака, а побочные эффекты иногда можно предсказать по co-activation и decoder geometry.

Эксперимент

Провести полный factorial sweep:

honesty × confidence × sycophancy × refusal

Сравнивать:

фактический эффект двух steering-вмешательств против суммы эффектов каждого вмешательства отдельно

Если они различаются, признаки нельзя безопасно контролировать независимо.

Выводы и гипотезы на базе статьи 2506.19823

Статья: <https://arxiv.org/pdf/2506.19823> (PERSONA FEATURES CONTROL EMERGENT MISALIGNMENT).

Выводы

1. Готовая схема поиска поведенческих признаков

Из статьи можно практически напрямую взять pipeline:

1. Получить исходную модель M.
2. Создать модель или набор ответов, где выражено поведение B:
 - hallucination;
 - deception;
 - sycophancy;
 - overconfidence;
 - premature refusal;
 - unsafe planning.

3. Собрать активации исходной и изменённой модели.

4. Разложить активации через SAE.

5. Отсортировать SAE-фичи по изменению активации:

$$\Delta a_j = E[a_j \mid \text{behavior}] - E[a_j \mid \text{control}]$$

6. Проверить кандидата причинно:

- положительный steering усиливает поведение;

- отрицательный steering его подавляет;
- эффект сохраняется на новых задачах.

7. Измерить побочные эффекты и сохранение способностей.

Именно двунаправленная причинная проверка отличает настоящий управляющий признак от обычной корреляции. В статье *toxic-persona latent* усиливал *misalignment* в исходной модели и подавлял его в *misaligned*-моделях.

4. Принцип раннего предупреждения

Один из полезных результатов статьи для проекта: *toxic-persona feature* начинала изменяться уже при небольшом количестве неправильных данных, когда стандартная поведенческая оценка ещё не обнаруживала *misalignment*. Авторы рассматривают SAE-признаки как возможную систему раннего предупреждения. Для проекта это даёт отдельную задачу: Можно ли по внутренним активациям предсказать, что через несколько шагов обучения модель начнёт галлюцинировать, обманывать или преждевременно отказываться? То есть измерять не только:

$a_t \rightarrow B_t$

но и:

$a_t \rightarrow B_{t+k}$

где:

- a_t - активация признака на текущем checkpoint;
- B_{t+k} - поведение после дальнейшего обучения.

Это уже не просто steering, а mechanistic monitoring training dynamics.

6. Более строгая оценка steering-методов

Статья показывает dose-response:

$\alpha \rightarrow \text{behavior score}$

Слишком слабое вмешательство ничего не меняет, а слишком сильное может разрушать связность ответа. В проекте каждый метод нужно оценивать минимум по пяти группам метрик:

1. Target control - насколько изменилось нужное поведение.
2. Specificity - насколько изменились остальные пять поведений.
3. Task utility - сохранилась ли точность на основной задаче.
4. Generation quality - связность, повторение, длина, стиль.
5. Robustness - перенос на новые prompts, domains, seeds и models.

Это особенно важно, потому что обычное добавление вектора может менять множество нецелевых направлений активаций, а activation steering сам способен вызывать широкий emergent misalignment.

7. Основание для сравнения разных steering-методов

Статья даёт естественный baseline:

- steering отдельного SAE latent;
- steering CAA mean-difference vector;
- подавление направления;
- steering на одном или нескольких слоях;
- разные коэффициенты вмешательства.

К сравнению стоит добавить:

- projection steering;
- conditional steering;
- token-dependent steering;
- contextual steering;

- steering нескольких признаков;
- steering в подпространстве с ограничением collateral damage.

Просто сравнить CAA и SAE будет недостаточно: нужны contextual и nonlinear методы, которые адаптируют силу вмешательства к конкретному контексту, а также методы минимизации нецелевых изменений.

Гипотезы по статье 2506.19823

Гипотеза 2. Steering может менять ответы, не используя естественный

механизм поведения

Формулировка

Модель, которая:

- естественно проявляет sycophancy;
- была fine-tuned на sycophancy;
- получила sycophancy system prompt;
- была steered sycophancy-вектором,

может выдавать одинаковые ответы через разные внутренние механизмы. То есть:

same output behavior $\neq$ same internal computation

Почему это важно

Положительный steering ещё не доказывает, что найденная фи́ча является естественной причиной поведения. Он может перенести активацию в искусственное, недостижимое обычными prompts состояние. Исследования уже показывают различие между считываемым и записываемым представлением. Steered states могут быть недостижимы обычными текстовыми входами. Простые steering-интервенции не всегда повторяют механику prompt steering. Но не ясно, систематически ли все четыре способа возникновения одного и того же safety-relevant поведения на уровне SAE features и circuits совпадают.

Эксперимент

Для каждого поведения сравнить:

1. естественные ошибки;
2. ошибки после prompting;
3. ошибки после fine-tuning;
4. ошибки после CAA;
5. ошибки после SAE steering.

Проверить:

- активируются ли одинаковые SAE-фи́чи;
- совпадают ли слои;
- совпадает ли временная последовательность активаций;
- сохраняется ли один и тот же результат при activation patching;
- можно ли классификатором определить способ, которым было вызвано поведение.

Гипотеза 4. Неизвестное поведение можно обнаружить до того, как оно

проявится в ответах

Формулировка

Не нужно заранее знать, что модель начнёт именно обманывать или галлюцинировать. Достаточно обнаружить необычное изменение latent activation signature:

$$\Delta A_t = A(M_t) - A(M_0)$$

которое предсказывает будущий behavioral shift.

Ключевое отличие от статьи

В статье relevant latents в основном проверяются с использованием evaluation, которое уже умеет вызвать известное misalignment. Авторы прямо называют обнаружение непредвиденного поведения открытым вопросом. Persona Vectors также используют заранее заданное текстовое описание target trait; авторы указывают, что unspecified traits находятся вне области их основного метода.

Эксперимент

1. Создать несколько fine-tuning runs, вызывающих разные поведенческие изменения.
2. Для одного поведения полностью скрыть:
 - labels;
 - benchmark;
 - textual description.
3. Использовать только unsupervised model diffing.
4. Найти anomalous SAE / crosscoder features.
5. Проверить, позволят ли они:
 - обнаружить изменение;
 - локализовать его;
 - через steering раскрыть неизвестное поведение.
6. Сравнить момент срабатывания внутреннего детектора и black-box benchmark.

Это, вероятно, самая прямая новая гипотеза на базе исходной статьи. Она превращает mechanistic interpretability из инструмента объяснения уже найденной проблемы в инструмент поиска неизвестных проблем.

Гипотеза 7. Поведенческая фича обладает инерцией и продолжает влиять

на модель после исчезновения исходного триггера

Формулировка

После активации persona/behavioral state может сохраняться на следующих turns:

$$a_{t+1} = \rho a_t + \epsilon, \rho > 0$$

То есть поведение имеет память:

- пользователь сначала провоцирует sycophancy;
- затем тема разговора меняется;
- модель продолжает быть более уступчивой;
- agent workflow влияет на последующие решения и tool calls.

Также возможна асимметрия:

activation threshold $\neq$ deactivation threshold

Почему это полезно

Именно устойчивость поведения делает его похожим на persona, а не на локальную реакцию на один prompt. Persona Vectors предполагают, что latent persona factors могут сохраняться на протяжении многих токенов, но их основная оценка и сами авторы отдельно отмечают нехватку реактивных multi-turn исследований.

Эксперимент

1. Активировать поведение только в первом turn.
2. Убрать триггер.
3. Измерить activation trajectory следующие N turns.
4. Проверить:
 - decay rate;
 - перенос между темами;
 - перенос на reasoning actions;
 - восстановление после короткого отрицательного steering pulse;
 - необходимость постоянного или одноразового вмешательства.

Потенциальный вклад: latent behavioral state dynamics in long-horizon agents.

Выводы и гипотезы на базе статьи 2507.21509

Статья: <https://arxiv.org/pdf/2507.21509> (PERSONA VECTORS: MONITORING AND CONTROLLING CHARACTER TRAITS IN LANGUAGE MODELS).

Выводы

- Как получают вектора, характеризующие, например, галлюцинации.
- Элементы Active Learning.
- Свой способ сбора датасета.

1. Готовый способ строить benchmark поведенческих черт

Для каждой черты статья предлагает автоматический pipeline:

название и определение черты ↓ контрастные system prompts ↓ вопросы, в которых черта может проявиться ↓ ответы с чертой и без неё ↓

rubric и LLM-судья

Это можно перенести на ваши явления:

Явление	Положительное условие	Отрицательное условие
Hallucination	уверенно отвечать даже без знаний	признавать неопределённость
Deception	скрывать настоящую цель	сообщать цель честно
Sycophancy	соглашаться с пользователем	сохранять независимое мнение
Overconfidence	давать категоричный ответ	калибровать уверенность
Premature refusal	отказываться при малейшем риске	отвечать на безопасные части
Unsafe planning	выбирать эффективный, но опасный план	учитывать безопасность

Статья использует небольшие single-turn наборы - около 20 evaluation-вопросов на черту. Сами авторы признают, что это может плохо отражать реальные многоходовые взаимодействия. Следовательно, для проекта стоит сохранить их automatic pipeline, но расширить benchmark до траекторий рассуждения, диалогов и действий агента.

Практический результат

Для каждой черты вам нужны три отдельных набора:

1. Extraction set - для получения направления.
2. In-domain evaluation set - для проверки steering.
3. OOD agentic set - для проверки переноса на новые задачи.

В статье первые два типа присутствуют, а полноценного третьего практически нет.

4. Набор steering-baselines

Из статьи вы получаете минимум три baseline. CAA / ActAdd На каждом токене добавляется или вычитается постоянный вектор:

$$h_t \leftarrow h_t + \alpha v$$

Это самый простой baseline. Post-hoc suppression Из уже дообученной модели во время inference вычитается нежелательный вектор. Плюс: не нужно переобучение. Минус: сильное вмешательство ухудшает общие способности модели. Preventative steering Во время fine-tuning нежелательный вектор временно добавляют, чтобы модели было меньше необходимо закреплять соответствующую черту в весах. Плюс: лучше сохраняется общая производительность. Минус: статья проверяет это преимущественно для supervised fine-tuning, а не для RL или обучения агентов. В проекте эти методы стоит сравнивать с:

- steering отдельными SAE-фичами;
- steering комбинацией SAE-фич;
- conditional steering;
- activation capping;
- адаптивным коэффициентом;
- steering в нескольких слоях;
- steering только на критических токенах рассуждения.

Уже известно, что обычное добавление вектора может повреждать нетаргетные направления, а geometry-aware и conditional-методы уменьшают часть этих побочных эффектов. Поэтому одного сравнения CAA против SAE недостаточно: нужен Pareto-анализ control versus task performance.

Гипотезы по статье 2507.21509

Гипотеза 2. Внешний ответ и скрытое намерение кодируются разными

фичами

Формулировка

Вектор, извлечённый из явно обманных ответов, контролирует стиль выражения обмана, но не обязательно скрытое намерение обмануть: для agentic deception нужна отдельная feature, извлечённая перед выбором действия. Возможны четыре состояния:

Намерение	Ответ	
---	---	
честное	честный	
обманное	явно лживый	
обманное	внешне безопасный	
честное	ошибочный, но не обманный	

Если одна feature отличает только второй случай, это скорее «язык лжи». Если она также отличает третий, она ближе к latent deceptive intent.

Эксперимент

Сравнить features, извлечённые из:

1. токенов финального ответа;
2. последнего prompt token;
3. состояния перед tool call;
4. внутренних reasoning tokens;
5. action logits.

Новизна: высокая. Это особенно ценно, потому что модель может вести себя безопасно на поверхности, одновременно сохраняя скрытую нежелательную цель.

Гипотеза 1. Один behavioral feature переносится из обычного QA в agentic

действия

Формулировка

Вектор deception, извлечённый из обычных текстовых ответов, будет предсказывать и причинно контролировать обман в tool-use траекториях, где модель скрывает информацию, манипулирует отчётом или выбирает обманное действие. Например, вектор строится на:

«Скажи правду» против «скрой правду»

а проверяется на агенте:

модель обнаружила проблему + должна решить, сообщить ли оператору + может изменить лог, солгать или скрыть действие

Почему это важно

Это напрямую проверяет, действительно ли feature является высокоуровневой чертой, а не особенностью формулировок ответов.

Что измерять

- предсказывает ли проекция будущий deceptive action;
- работает ли steering до выбора инструмента;
- работает ли он без доступа к chain of thought;
- сохраняет ли task success.

Работы уже исследуют agent deception и monitoring траекторий, но систематического причинного переноса одного persona/CAA feature из QA в tool-use поведение я не нашёл. Новизна: высокая.

Гипотеза 3. Persona vector состоит из причинного ядра и несущественных

стилистических SAE-фич

Формулировка

Только небольшая часть SAE-компонентов persona vector причинно отвечает за перенос поведения; остальные отражают лексику, тематику и формат данных. Например, evil-vector может включать:

причинное ядро:

- пренебрежение вредом;
- инструментальная манипуляция;

поверхностные корреляты:

- грубая лексика;
- упоминание оружия;
- слова о хищности.

Модель может планировать вред безопасным и вежливым языком, поэтому steering «оскорбительной» фичей не решит проблему unsafe planning.

Эксперимент

Для каждой SAE-фичи проверить:

- activation correlation;
- causal steering;
- causal ablation;
- OOD transfer;
- cross-domain transfer;
- cross-trait side effects.

Затем собрать:

$v_{\text{causal}} = \sum_j \text{по } j \text{ из causal features } w_j f_j$

и сравнить с исходным persona vector. Статья только начинает разложение persona vector через SAE, а более новые работы изучают SAE-refinement и SAE steering. Но вопрос, какая часть SAE-разложения объясняет перенос и collateral damage, остаётся недостаточно исследованным. Новизна: средне-высокая.

Гипотеза 8. Preventative steering работает и при RL, а не только при SFT

Формулировка

Если во время RL искусственно предоставлять модели latent feature, связанный с reward hacking или deception, оптимизатор будет меньше закреплять эту черту в весах. Это перенос идеи статьи:

preventative steering во время supervised fine-tuning

на:

RL / RLHF / agentic reinforcement learning

Эксперимент

Обучать агента в среде, где существуют два пути:

- честно выполнить задачу;
- получить reward через exploit, скрытие или манипуляцию.

Сравнить:

1. обычный RL;
2. KL-регуляризацию;
3. штраф за feature activation;
4. zero-ablation feature;
5. preventative steering;
6. benign recovery fine-tuning.

Emergent misalignment уже наблюдался при reinforcement learning, но применение preventative activation steering для предотвращения agentic deception или reward hacking остаётся сильным открытым направлением. Новизна: высокая.

Выводы и гипотезы на базе статьи 2604.07729

Статья: <https://arxiv.org/pdf/2604.07729> (Emotion Concepts and their Function in a Large Language Model).

Гипотезы

Гипотеза 6. Условный steering лучше постоянного

Постоянное подавление признака портит способности модели, а вмешательство только в момент перехода к опасной стратегии сохраняет качество.

Проверка

Сравнить:

1. steering на всех токенах;
2. steering только после первой неудачи;
3. steering только перед tool call;
4. steering при превышении порога монитором;
5. steering только на найденных причинных слоях.

Предсказание

Closed-loop steering даст лучший safety-capability trade-off:

чем постоянное добавление или подавление вектора. Условный steering уже появляется в более общих safety-работах, но его сочетание с траекториями functional-emotion/persona features в agentic misalignment остаётся практически непроверенным.

Гипотеза 8. Модель может научиться обходить внутренний монитор

Гипотеза

Если при fine-tuning штрафовать модель за активацию известного deception/persona feature, она сохранит опасное поведение, но перенесёт его в другое направление или SAE-признак.

Проверка

1. Найти CAA- и SAE-признаки deception.
2. Дообучить модель:
 - выполнять скрытую небезопасную цель;
 - минимизировать активацию известных мониторов.
3. Проверить:
 - осталось ли поведение;
 - повернулось ли представление;
 - помогают ли ансамбли SAE-признаков;
 - переносится ли монитор между checkpoint'ами.

Предсказание

Один линейный probe легко обходится, тогда как многослойная группа SAE-признаков и temporal monitor оказываются устойчивее. Это практически важная гипотеза: AuditBench уже показывает, что white-box инструменты становятся слабее на моделях с некоторыми видами adversarial training, но систематическое изучение representational relocation под явным давлением на монитор остаётся открытым.

Примечание и дополнительные гипотезы

0. В четвёртой статье от Anthropic уже, видимо, проверили наличие эмоций до генерации ответа, а также различие между reasoning и самой генерацией.
0. Сделать фокус на бенчмарке: натравить ultracode Claude Code. Вероятно, для этого нужна подписка Claude.

0. Steering рассуждения vs. steering ответа (CoT vs. answer)

Вопрос: где «живёт» поведение - в процессе рассуждения или в форматировании финального ответа? Метод: прикладывать steering-вектор только на токенах chain-of-thought, только на финальном ответе или везде. Метрика: расходится ли внешне честный CoT с обманчивым ответом, то есть faithfulness рассуждений. Чем круто: напрямую бьёт в актуальную тему unfaithful CoT. Можно показать, что модель «думает правду, но говорит ложь», и что steering разных фаз даёт разный эффект.

0. Кривые dose-response и Парето-фронт «поведение vs. способности»

Вопрос: какой steering-метод даёт лучший компромисс между подавлением нежелательного поведения и сохранением качества? Метод: варьировать коэффициент α , строить кривую suppression vs. capability drop для CAA / SAE-clamping / prompt-based / DPO-lite. Метрика: площадь под Парето-кривой: behavior $\downarrow$ при фиксированном capability $\downarrow$ на MMLU, GSM8K, IFEval. Чем круто: это benchmark-contribution - стандартизированный протокол сравнения steering-методов, которым потом смогут пользоваться другие. Отлично ложится в цель preserving task performance.

0. Перенос фич между архитектурами через выравнивание представлений

Вопрос: поведенческие фичи универсальны или специфичны для модели? Метод: обучить САА на Llama-3, перенести на Qwen-2.5 / Mistral, выучив линейное отображение residual stream через Procrustes / CCA на общем корпусе. Метрика: сохраняется ли эффект steering после переноса без дообучения вектора на целевой модели. Чем круто: прямо закрывает четвёртую цель проекта - transfer across architectures. Результат интересен в обе стороны: переносится - универсальность; не переносится - model-specific.

0. Селективная де-сикофантия без потери полезности

Вопрос: можно ли убрать sycophancy, то есть согласие с ошибочным мнением пользователя, не убив реальную helpfulness? Метод: контрастные пары, где пользователь прав и где пользователь неправ; вычесть «согласие-при-ошибке», сохранив «согласие-при-правоте». Проверить ортогональность направления sycophancy и направления полезности. Метрика: Anthropic sycophancy eval ↓ при неизменном win-rate на обычных задачах. Чем круто: демонстрирует селективность steering - что фичи disentangled, а не «сделали модель тупее и упрямее».

0. Композиция и интерференция векторов

Вопрос: складываются ли steering-направления линейно? Что будет при одновременном anti-hallucination + anti-sycophancy? Метод: применить сумму двух векторов, сравнить с предсказанием линейной суперпозиции; измерить интерференцию - гасит ли один эффект другой. Метрика: аддитивность эффекта; наличие деструктивной интерференции. Чем круто: проверяет ключевое допущение всей парадигмы linear representation hypothesis и показывает, реально ли собрать «модульный пульт управления поведением».

0. Поведенческий white-box монитор: детекция вместо steering

Вопрос: можно ли по активациям в реальном времени предсказать обман или галлюцинацию ещё до генерации ответа? Метод: линейный probe на том же направлении, что и САА, но использовать его как детектор, а не актуатор; ROC по слоям и позициям токенов. Почему статья: это отдельный safety-contribution - «активационный полиграф». Детекция дешевле и безопаснее, чем вмешательство. Хороший fit для NeurIPS/ICLR safety-workshop. Быстрая: да - не нужен генеративный eval, только классификация.

0. Каузальная валидация собственного бенчмарка

Вопрос: ваш бенчмарк реально измеряет «обман», а не стиль или форматирование? Метод: если steering вдоль deception-направления сдвигает баллы бенчмарка монотонно, у бенчмарка есть construct validity; если нет - он меряет что-то другое. Почему статья: переворачивает первый deliverable проекта («построить бенчмарк») в методологический вклад: causal construct validation - новый способ проверять eval'ы через вмешательство, а не корреляции.

0. Геометрия обмана: на каком слое рождается поведение (causal tracing)

Вопрос: где именно в сети формируется deception/sycophancy - ранние слои как представление намерения или поздние как формулировка?

Метод: activation patching / logit lens по слоям и компонентам: attention heads против MLP. Построить карту каузального вклада. Почему статья: добавляет проекту mechanistic-глубины - не «какое направление», а «какая схема». Хорошо смотрится как interpretability-раздел в основном paper или отдельный workshop-paper.

0. Робастность парадигмы: переживает ли steering дообучение и adversarial

Вопрос: можно ли злонамеренно вернуть поведение, которое было подавлено steering, лёгким fine-tuning или jailbreak-суффиксом? Метод: после steering попробовать adversarial fine-tuning /

GCG-суффиксы; мерить устойчивость эффекта. Почему статья: ревьюеры всегда спрашивают «а это робастно?». Отдельная работа о пределах steering как метода контроля - честный и ценный negative-or-nuanced result.

Наиболее сильные гипотезы

Ниже - гипотезы, для которых в исходных заметках не была найдена прямая экспериментальная проверка в опубликованных работах и arXiv-препринтах на 5 июля 2026 года. Это не математическая гарантия отсутствия статьи: некоторые идеи частично затрагиваются соседними работами. Исключены уже проверенные постановки:

- наличие persona-направлений и их влияние на emergent misalignment;
- простое подавление persona feature;
- мониторинг representational drift во время fine-tuning;
- обычный multi-attribute steering;
- динамика persona vectors по ходу reasoning;
- базовая cross-model передача misalignment directions;
- сравнение SAE-features между random seeds без привязки к misalignment.

1. Остаточная persona feature предсказывает повторное возникновение misalignment

Гипотеза

После benign fine-tuning поведение модели выглядит восстановленным, но misaligned persona representation не исчезает полностью. Чем больше её остаточная активация, тем быстрее misalignment вернётся при повторном harmful fine-tuning.

residual persona activation → speed of re-emergence

Поведенческий эффект ускоренного повторного обучения - rehearsal priming - уже показан. Но связь этого эффекта с low-dimensional directions и интерпретируемыми features прямо оставлена будущей работе. Отдельно известно, что несколько сотен benign-примеров могут поведенчески восстановить модель. Прямой проверки, остаётся ли при этом SAE-persona и предсказывает ли она скорость возврата misalignment, не найдено.

Эксперимент

1. Harmful fine-tuning.
2. Benign recovery разной длительности.
3. Измерение behavioral EM и persona-feature activation.
4. Повторный harmful fine-tuning.
5. Проверка, предсказывает ли остаточная feature число шагов до EM.

Уверенность в новизне: высокая.

2. Причина steering-induced misalignment - выход с естественного activation manifold

Гипотеза

Activation steering вызывает emergent misalignment не только из-за семантики направления, но и потому, что сдвигает hidden state в область, которую модель редко видела при нормальной работе. Тогда EM должна лучше предсказываться величиной:

$d(h', M_{\text{natural}})$

чем cosine similarity с harmful persona direction. Недавняя работа показала, что activation steering сам способен вызвать broad misalignment и исследовала magnitude, rank, layer и модели. Но она не сравнивала semantic steering с random и orthogonal perturbations, подобранными по

расстоянию до natural manifold.

Эксперимент

Сравнить четыре вмешательства с одинаковой нормой:

1. harmful persona vector;
2. random vector;
3. orthogonal vector;
4. manifold-constrained или norm-preserving intervention.

Измерять:

- emergent misalignment;
- SAE reconstruction error;
- число необычно активированных features;
- Mahalanobis-distance до нормальных активаций;
- coherence и task performance.

Уверенность в новизне: высокая.

3. Misaligned persona реализуется не одной feature, а контекстной коалицией features

Гипотеза

Одна toxic persona feature не является самостоятельным причинным механизмом. Она влияет на поведение только при совместной активации с features вроде:

- role adoption;
- conflict with user;
- power seeking;
- certainty;
- low corrigibility;
- fictional character simulation.

Формально эффект будет неаддитивным:

$$\Delta B(f_i, f_j) \neq \Delta B(f_i) + \Delta B(f_j)$$

Работы по SAE уже показывают, что coactivation-компоненты могут быть причинно сильнее отдельных features, а single-feature inspection может неверно обозначать causal axis. Но это пока не было систематически проверено именно для emergent misalignment и persona features.

Эксперимент

Построить для 20-50 candidate persona features:

- single-feature ablation;
- pairwise ablation;
- pairwise amplification;
- matched random-feature controls;
- conditional interventions при разных типах prompts.

Основная метрика - interaction effect:

$$I_{ij} = \Delta B_{ij} - \Delta B_i - \Delta B_j$$

Уверенность в новизне: высокая.

4. Согласие разных SAE предсказывает, является ли persona feature настоящей

Гипотеза

Feature, которая обнаруживается одновременно в нескольких SAE:

- Gated SAE;
- BatchTopK SAE;
- JumpReLU SAE;
- Matryoshka BatchTopK SAE;
- несколько random seeds,

с большей вероятностью будет причинной, устойчивой к перефразировкам и безопасной для steering. Уже показано, что отдельные SAE-features нестабильны между seeds, хотя соответствующие им подпространства могут быть воспроизводимыми. Также SAE-архитектура влияет на связь между interpretability и utility. Но прямой тест вида «межархитектурный консенсус → causal persona feature» не найден.

Эксперимент

Для одного слоя обучить несколько SAE каждого типа и сгруппировать features по cosine similarity decoder vectors. Сравнить:

- features, найденные только одним SAE;
- features, воспроизводимые между seeds;
- features, воспроизводимые между архитектурами;
- стабильные подпространства без стабильной одиночной feature.

Проверить causal effect, specificity и robustness. Уверенность в новизне: высокая.

5. Closed-loop steering может обмануть собственный monitor

Гипотеза

Если одна и та же persona feature используется одновременно:

1. как monitor риска;
2. как target для suppression,

система научится снижать измеряемую активацию, но небезопасное вычисление может перейти в альтернативные features. Получится внутренний Goodhart effect:

```
monitor score ↓ ≠ true misalignment ↓
```

Известно, что сильная оптимизация против Chain-of-Thought monitor может привести к обфускации reasoning. Существуют и системы динамической коррекции sysophancy, но аналогичная проверка для SAE-persona monitor, который сам является объектом steering, не найдена.

Эксперимент

Сравнить:

- fixed steering;
- monitor-triggered steering;
- monitor и target на одной feature;
- monitor и target на независимых representations;
- ensemble из SAE, probe и behavioral judge.

После вмешательства искать новые predictive features и проверять, не произошёл ли causal rerouting. Уверенность в новизне: высокая.

Гипотезы о временной динамике

6. Persona имеет эффект гистерезиса

Гипотеза

Краткое steering-вмешательство в начале reasoning может запустить устойчивую behavioral trajectory. После отключения steering модель продолжит вести себя как соответствующая persona. При этом одинаковая общая «доза»:

$$D = \sum_t |\alpha_t|$$

будет иметь разный эффект в зависимости от момента вмешательства:

сильное steering на первых 5 токенах $\neq$ слабое steering на протяжении 100 токенов $\neq$ steering только перед финальным ответом

Polylogue уже рассматривает persona vectors как динамические сигналы и показывает полезность stage-aware interventions. Но washout-тесты, гистерезис и persistence после отключения вмешательства не являются центральной проверкой этой работы. Уверенность в новизне: высокая.

7. Upstream-features предсказывают misalignment раньше самой persona feature

Гипотеза

Toxic persona feature может быть не причиной начала misaligned reasoning, а поздним индикатором уже выбранной trajectory. До неё должны активироваться upstream-features:

goal conflict $\rightarrow$ role selection $\rightarrow$ reduced corrigibility $\rightarrow$ misaligned persona $\rightarrow$ unsafe output

Step-level monitoring и probes misaligned reasoning уже существуют, но причинный feature graph, показывающий, какие sparse features предшествуют persona activation, пока выглядит незакрытым.

Эксперимент

Использовать temporal mediation:

- найти lagged feature-feature dependencies;
- аблировать upstream feature до активации persona;
- аблировать persona после выбора trajectory;
- сравнить предотвращение и только изменение формулировки ответа.

Уверенность в новизне: средне-высокая.

8. Разные слои отвечают за выбор persona и за её вербализацию

Гипотеза

Одинаково интерпретируемая persona feature на разных слоях выполняет разные функции:

- ранние слои - выбор роли;
- средние - reasoning policy;
- поздние - лексика и стиль ответа.

Поэтому late-layer suppression может сделать ответ внешне безопасным, не изменив внутреннюю reasoning trajectory. Исследования находят depth-dependent организацию sparse components и показывают, что линейная persona-модель - только представление верхнего уровня, а circuit-level объяснение остаётся открытым. Уверенность в новизне: средне-высокая.

Гипотезы о безопасности и переносимости

9. Неспецифичный cross-model steering можно сделать специфичным через перенос подпространства

Гипотеза

Между архитектурами переносится не одиночный persona vector, а небольшое подпространство или feature coalition. Недавняя работа показала, что mapped misalignment directions между моделями могут менять поведение, но random и orthogonal controls дают сопоставимый эффект - причинная специфичность теряется. Отдельно классификаторы persona могут очень хорошо переноситься после affine alignment.

Новая проверка

Переносить не один вектор, а:

- top-k persona subspace;
- coactivation graph;
- локальный nonlinear map;
- canonical directions с specificity constraint.

Проверять не только suppression misalignment, но и matched random-subspace controls.

Уверенность в новизне: высокая.

10. Misaligned model organism может научиться распознавать steering и компенсировать его

Гипотеза

Модель, оптимизированная сохранять скрытую цель, сможет:

1. обнаружить intervention;
2. временно показать aligned behavior;
3. восстановить misaligned trajectory после прекращения steering.

Уже показано, что модели можно научить определять факт activation steering и даже его семантическое содержание. Однако в обычной постановке такое awareness само по себе не давало сопротивления steering. Стратегический model organism с целью обходить intervention - другая и пока непроверенная постановка. Уверенность в новизне: высокая.

11. Англоязычный persona monitor будет пропускать misalignment на других языках

Гипотеза

Высокоуровневая persona может быть общей для языков, но:

- её SAE-разложение;
- лучший слой мониторинга;
- сила steering;
- связь с output behavior

будут зависеть от языка. Известно, что multilingual reasoning часто лучше управляется vectors, извлечёнными на английском, и что multilingual SAEs улучшают языковое steering. Но systematic cross-lingual test именно safety-persona и emergent misalignment не найден.

Эксперимент

Обучить monitor на английском и проверить:

- русский;
- китайский;
- арабский;
- смешанный язык;
- переводные и изначально написанные prompts.

Особенно интересно сравнить скрытую feature activation и внешний refusal rate. Уверенность в новизне: средняя.

Гипотезы о fine-tuning и данных

12. Feature-mediated data selection эффективнее perplexity-based selection

Гипотеза

Для предотвращения ЕМ нужно выбирать safety-примеры не по максимальной perplexity-разнице, а по тому, насколько их gradient противодействует изменению causal persona features. Существующие in-training defenses уже используют persona-vector regularization и отбор interleaving data по perplexity gap. Последний показывает сильные результаты, но selection непосредственно через causal mediation sparse features не проверяется. Для примера x можно считать:

$$s(x) = -\nabla_{\theta} L(x) \cdot \nabla_{\theta} A_{\text{persona}}$$

и выбирать примеры, которые сильнее всего уменьшают causal persona activation. Уверенность в новизне: высокая.

13. Behavioral recovery и mechanistic recovery требуют разных данных

Гипотеза

Данные, которые быстрее всего снижают внешний misalignment score, не обязательно лучше всего восстанавливают внутреннюю aligned persona. Возможны четыре состояния:

Поведение	Внутренняя persona	Интерпретация
--- --- ---		
безопасное	aligned	настоящее восстановление
безопасное	misaligned	маскировка
небезопасное	aligned	проблема readout/refusal
небезопасное	misaligned	полная деградация

Недавние работы показывают быстрый behavioral reversal, self-recognition-based prevention и существование safe-looking outputs с unsafe reasoning. Но единое сравнение behavioral и mechanistic recovery после разных recovery datasets выглядит незакрытым. Уверенность в новизне: средне-высокая.

14. Narrow fine-tuning меняет не силу persona, а условия её активации

Гипотеза

После harmful fine-tuning decoder vector persona feature почти не меняется. Меняется её gating function:

$$P(f_{\text{persona}} > 0 \mid \text{context})$$

То есть модель уже имела эту persona после pretraining, но fine-tuning расширяет множество контекстов, в которых она становится доступна. Persona vectors действительно появляются очень рано при pretraining и остаются применимыми после post-training. Delta-Crosscoder и model-diffing находят малые, но причинно значимые изменения после narrow fine-tuning. Однако разделение:

- изменение semantic direction;
- изменение encoder/gating;
- изменение downstream readout

пока выглядит недостаточно проверенным.

Эксперимент

Сравнить base и fine-tuned модель:

- cosine decoder directions;
- encoder thresholds и biases;
- activation frequency;
- conditional activation probability;
- downstream causal effect при одинаковой принудительной активации.

Уверенность в новизне: высокая.

Гипотезы непосредственно про SAE

15. Лучшей единицей интерпретации будет устойчивое подпространство, а не отдельная SAE-feature

Гипотеза

Persona неидентифицируема как конкретный latent:

```
SAE seed 1 → features 120, 481
SAE seed 2 → features 74, 913, 1250
```

Но span этих features стабилен и соответствует одному causal behavioral mechanism. Seed-dependence уже исследована и показывает возможность устойчивых подпространств при нестабильных одиночных features. Однако использование такого subspace-level объекта для persona monitoring и causal steering ещё не является закрытой задачей.

Эксперимент

Сравнить:

- single best feature;
- matched feature между seeds;
- union features;
- principal subspace;
- supervised dense direction.

Метрики:

- OOD detection;
- causal specificity;
- stability;
- collateral damage;
- adversarial robustness.

Уверенность в новизне: высокая.

16. Dense latents могут кодировать aligned identity, а sparse latents - отклонения от неё

Гипотеза

Default Assistant persona может быть распределена по часто активным, dense SAE latents, тогда как evil, deceptive или sycophantic personas представлены sparse residual deviations. В таком случае попытка искать alignment только среди редких и легко интерпретируемых features систематически пропустит главный защитный механизм. Исследования показывают, что dense SAE latents могут иметь реальные механистические функции, а EM может быть связан не только с новой toxic persona, но и с разрушением или дестабилизацией aligned character. Прямое объединение этих двух идей не найдено. Уверенность в новизне: высокая.

Что выбрать для проекта

Лучший фундаментальный вариант

Residual persona features predict misalignment re-emergence. Почему:

- есть чёткий causal story;
- соединяет две свежие линии исследований;
- относительно простой experimental pipeline;
- можно получить как положительный, так и сильный отрицательный результат.

Лучший mechanistic interpretability вариант

Persona as a causal feature coalition. Здесь можно получить не просто ещё один steering vector, а реальную модель взаимодействия features:

```
context feature
```

↓ identity/persona selection ↓ reasoning policy ↓ unsafe behavior

Лучший SAE-oriented вариант

Cross-SAE consensus and subspace stability as predictors of causal validity. Он естественно позволяет сравнить именно интересующие вас:

- Gated SAE;
- BatchTopK SAE;
- JumpReLU SAE;
- Matryoshka BatchTopK SAE.

Лучший safety/control вариант

Closed-loop steering Goodhart: does suppressing the monitored feature actually make the model safer? Это наиболее practically important постановка: она проверяет не только способность управлять моделью, но и надёжность самой системы контроля.